

TREBALL DE FINAL DE GRAU

Pipeline ETL per a la Prospecció Comercial

Automatització modular en Python per a processos B2B

Dante Rodríguez Milán

Universitat Autònoma de Barcelona · 2026

 @dxnetft  Portfolio  LinkedIn



Agenda



01. Context

Identificació i anàlisi del problema i silos de dades actuals.



02. Objectius

Metes estratègiques d'automatització i qualitat de dades.



03. Arquitectura

Disseny modular del motor centralitzat i fases del pipeline.




04. Resultats

Validació, conclusions i demostració final del sistema.

Context de **Negoci**

La prospecció comercial B2B depèn de dades de qualitat.

- **L'impacte de les dades incorrectes:** Pèrdua de temps, contactes erronis i menys capacitat de captació
- **El repte de la fragmentació:** Les dades dels prospectes provenen de múltiples plataformes especialitzades, no d'una única font.



Actors del Context



Plataforma d'execució comercial



zoominfo

Intel·ligència comercial B2B

(LeadGenius)



Contactes verificats

El Repte de la Dada Fragmentada

El problema no és que faltin dades, sino que estan disperses en múltiples plataformes, amb formats diferents i nivells de qualitat diferents

Silos de Dades


Fonts independents sense integració ni visió unificada de prospectes.

Qualitat Deficient

Duplicats i formats inconsistents que obliguen a validacions manuals lentes i propenses a errors humans.

Cost operatiu elevat

Creixement lineal segons les tasques a fer i la quantitat de prospectes, arribant a exigir 24h per execució en fulls de càlcul sense traçabilitat ni auditoria.



Impacte del Problema

Aquesta situació genera tres conseqüències importants.

Característica	Procés Actual
Temps d'execució	2 - 32 Hores
Qualitat de Dades	Errors humans freqüents
Consolidació	Multiples fitxers Excel separats
Traçabilitat	Sense auditoria, cap registre ni logs

Les dades existeixen, però no es poden convertir fàcilment en valor de negoci.

Objectius de **Negoci**

El pipeline ETL té un propòsit clar: generar impacte real en l'activitat comercial.



Identificar millor els clients potencials

Obtenir dades més completes, precises i verificades per enfocar els esforços en els comptes correctes.



Millorar la captació i retenció de clients

Aportar informació de qualitat que incrementa la conversió, millora el seguiment i reforça la relació amb els clients.



Optimitzar els processos comercials

Automatitzar i centralitzar el flux de dades per reduir temps operatiu, errors i costos, i escalar el negoci amb dades fiables.



Millors dades → Millors decisions → Millors resultats de negoci

Com ho aconseguim?



Automatització

Processar les 3 fonts amb un pipeline unificat i reutilitzable.



Qualitat

Implementació de validacions rigoroses d'emails, duplicats i formats.



Centralització

Unificar dades en un Deliverable llest per a importar directament al CRM.



Eficiència

Reducció radical del temps operatiu per optimitzar recursos humans.

Arquitectura del Pipeline ETL

Flux de dades del sistema



Account Setup (Fase 1)

Abans de processar prospectes, primer garanteixo que la base de comptes és correcta.



Accounts.xlsx (CRM)

Exportació del CRM
(172k registres)



Neteja i Enriquiment

- ✓ Neteja d'URLs
- ✓ Extracció de dominis
- ✓ Normalització de país
- ✓ Detecció de duplicats
- ✓ Filtratge de comptes ficticis (dummy)



Accounts.csv

Base validada
llest per al processament



176

comptes carregats
i validats ✓



Base de comptes validada = fonament del pipeline

Garantim qualitat, consistència i traçabilitat abans de processar prospectes.

Processament **per fases**

Cada font aplica regles específiques abans de la consolidació final.



Exportació i integració CRM (Fase 5)

L'objectiu final no és generar dades, sinó generar dades utilitzables pel negoci.



Llest per a negoci

Sense modificacions manuals addicionals.



Estalvi de temps

De hores de treball manual a minuts d'execució.



Qualitat assegurada

Dades validades i coherents abans d'arribar al CRM.



Impacte directe

Prospecció més eficient, més oportunitats.

Decisió arquitectònica clau

Disseny Config-Driven

Centralitzem la lògica en un únic motor reutilitzable i configurem cada font amb diccionaris.



Garantia de Qualitat de Dades

Abans d'arribar al CRM, el sistema va detectar 89 incidències potencials.

10

Controls Automàtics

✉ Format Email Regex

👤 Email-Nom Fuzzy Match

🌐 Validació Codi País ISO

🔗 URL LinkedIn Vàlida

🏢 Match Domini Empresa

🔒 Domini Privat (Gmail/Hotmail)

♂️ Detector de Gènere

📄 Detecció de Duplicats

☎ Format E.164 (Telèfon)

📊 Validació de Threshold

Impacte i Resultats de Negoci

Automatització, qualitat i escalabilitat que generen valor real per al negoci.



>95%

Estalvi de temps

De 4-6 hores manuals
a <3 segons de processament
automàtic per a les
fases principals.



1303

Incidències detectades
abans del CRM

Errors, duplicats i incoherències
identificats i corregits abans
d'arribar a la base de dades
del CRM.



1208

Prospectes nets
lliurats

Dades consolidades, validades
i llistes per a la importació
massiva al CRM.



366-953

Registres / segon

Rendiment en les fases
automàtiques del pipeline.
(sense tenir en compte
els canvis manuals)



Parcialment
escalable

Escalabilitat

100% escalable per incorporar
noves fonts de dades.
No dissenyat per a volums
molt grans de dades.



Resultat final: **dades de qualitat** que impulsen la captació i retenció de clients.



Visió unificada de prospectes



Decisions més ràpides i informades



Eficiència operativa



Avantatge competitiu

Gràcies per la vostra atenció

Alguna pregunta?

Dante Rodríguez Milán

TFG Enginyeria de Dades · UAB

 github.com/dxnetft

 Portfolio Personal

 LinkedIn Profile